

Inteligência Artificial | FGA0021 | Turma 01 | 2026.1

Professor: Dr. Fabiano Araujo Soares

Aluno: Bruno Cruz Garcia Rosa

Matrícula: 222006605

Deep Learning

1. Explicação do Problema

O problema abordado neste projeto consiste no desenvolvimento de um sistema computacional inteligente capaz de **decodificar e classificar imagens** estáticas correspondentes ao alfabeto da **Linguagem de Sinais Americana (ASL)**.

Gestos manuais capturados em cenários do mundo real apresentam variações severas de morfologia (tamanho e rotação dos dedos), oclusões parciais, sombras, diferentes tons de pele e ruídos de fundo nos ambientes. Diferente de algoritmos tradicionais que exigem a extração manual de características geométricas, a solução proposta utiliza o **Deep Learning** para mapear e aprender os padrões espaciais invariantes das imagens de forma 100% automatizada e hierárquica.

2. Abordagem Metodológica: Como a Rede foi Utilizada

2.1. Pipeline de Engenharia de Dados e Augmentation

O projeto foi alimentado utilizando o dataset real e público [ASL Alphabet](#), extraído de forma automatizada via API [kagglehub](#). O conjunto compreende um volume massivo de imagens divididas em **29 classes discretas**: 26 letras do alfabeto (A-Z) e 3 categorias funcionais de apoio dinâmico (*SPACE*, *DELETE* e *NOTHING*). O fluxo de tratamento de dados foi configurado em três etapas:

- **Redimensionamento e Otimização:** As matrizes originais de 200x200 pixels foram transformadas nativamente para a dimensão compacta de 64x64 com 3 canais de cor (**RGB**).
- **Regularização por Data Augmentation:** Aplicou-se transformações estocásticas no conjunto de treino (*train_transform*) incluindo espelhamento horizontal aleatório, inclinações angulares de até 15° (*RandomRotation*) e perturbações dinâmicas de 20% no brilho e contraste (*ColorJitter*). Esse arranjo impede que a rede memorize a iluminação ou a pose fixa de uma foto específica.
- **Particionamento:** Os dados foram segregados de forma isolada utilizando uma fração de validação de 20% (*VAL_RATIO = 0.2*). O conjunto de treinamento e validação recebeu a normalização baseada na distribuição estatística global da *ImageNet*.

2.2. Arquitetura Customizada AsICNN

A topologia da rede foi construída em **PyTorch** organizando o processamento em blocos convolucionais profundos:

- Camadas de Extração Local (Blocos 1, 2 e 3):** A rede emprega três blocos convolucionais sequenciais com filtros progressivos de 32, 64 e 128 mapas de características, todos com kernels de 3×3 e *padding* unitário. Cada bloco convolucional é imediatamente acoplado a uma camada de *BatchNorm2d()*, que normaliza as ativações dos lotes intermediários e acelera a convergência matemática. A redução de dimensionalidade espacial é executada por camadas de *MaxPool2d(2, 2)* (reduzindo os mapas de $64 \times 64 \rightarrow 32 \times 32 \rightarrow 16 \times 16 \rightarrow 7 \times 7$), seguidas por um descarte regularizador de *Dropout(0.25)*.
- Camada de Classificação Totalmente Conectada:** O mapa tridimensional final de **(128, 8, 8)** é achatado por um operador *Flatten()* em um vetor unidimensional de 8.192 características. Este vetor alimenta uma camada densa linear de 256 neurônios ocultos regulados por uma ativação **ReLU** e protegidos por um *Dropout(0.5)* agressivo. A camada de saída linear projeta as pontuações brutas (*logits*) diretamente para as 29 classes do problema, sendo computada sob a função de custo de **Entropia Cruzada Multiclasse** (*CrossEntropyLoss*) e atualizada via otimizador adaptativo **Adam**.

3. Resultados Obtidos e Análise das Métricas

O pipeline de Deep Learning foi executado de forma acelerada por hardware utilizando a API CUDA e registrando métricas a cada ciclo de treino.




Figura 1 – Curvas de Aprendizado (Loss e Accuracy)

Os resultados consolidados obtidos no final da décima época foram mapeados e organizados na tabela abaixo:

Tabela 1: Resumo Métrico do Desempenho da Rede Convolucional

Métrica Operacional	Valor Final	Comportamento Estatístico Observado
Acurácia de Treinamento	73,38%	Evolução gradual contida pelas restrições do Dropout ativo.
Acurácia de Validação	97,84%	Desempenho excepcional de generalização em dados limpos.
Loss de Treinamento	0,7218	Decaimento contínuo e suave sem picos de instabilidade.
Loss de Validação	0,1226	Curva descendente firme, comprovando ausência de overfitting.




Figura 2 – Matriz de Confusão do Alfabeto ASL

A análise das métricas aponta um fenômeno técnico notável: o desempenho de validação superou os indicadores de treinamento desde a primeira época. Isso reflete a eficácia dos blocos de Dropout e das técnicas de Data Augmentation. Como o descarte de neurônios e as distorções visuais operam unicamente na fase de treino, a rede é submetida a um cenário severo de aprendizado. Na fase de validação, com o Dropout desligado e diante de imagens de gestos perfeitamente limpos, a rede unifica seus pesos e exibe uma capacidade cirúrgica de predição, alcançando quase a totalidade de acertos (97,84%) sem registrar sinais de memorização (**overfitting**).

4. Considerações Finais e Limitações do Modelo

Ao utilizar múltiplos blocos estruturados de convolução e subamostragem local, a arquitetura extraiu com sucesso as geometrias finas e as orientações espaciais das mãos para cada uma das 29 categorias de gestos. A inclusão rigorosa de normalização em lote (**BatchNorm**) e o descarte aleatório (**Dropout**) garantiram a estabilidade numérica necessária para que o otimizador **Adam** conduzisse a rede a uma convergência rápida e de alta fidelidade estatística, operando de forma otimizada na GPU.

Contudo, a inspeção minuciosa da **Matriz de Confusão (Figura 2)** revelou gargalos intrínsecos de similaridade morfológica estrutural. Embora a diagonal principal exiba densidade absoluta de acertos (alcançando 97,84% de acurácia global), o modelo apresentou falhas sistemáticas localizadas de classificação em caracteres com alta correlação geométrica.

O caso mais severo ocorreu na classe **W**, onde a rede registrou 162 acertos, mas desviou 109 predições erroneamente para a classe **V**. Visualmente, ambos os gestos compartilham da mesma base de punho, diferenciando-se apenas pela extensão do terceiro dígito (dedo anelar); uma sutil variação angular ou sombreamento na captura faz com que os filtros convolucionais 3x3 extraiam mapas de ativação local análogos.

De forma semelhante, observou-se uma divergência menor na classe **R**, com 547 acertos e 49 classificações incorretas como **U**. Como a distinção entre os dois sinais repousa unicamente no cruzamento dos dedos indicador e médio, a compactação de entrada para 64x64 pixels associada à redução espacial da camada **MaxPool2d** tendeu a suavizar essa sobreposição fina de pixels, gerando a ambiguidade.