

Inteligência Artificial | FGA0021 | Turma 01 | 2026.1

Professor: Dr. Fabiano Araujo Soares

Aluno: Bruno Cruz Garcia Rosa

Matrícula: 222006605

Aprendizado não Supervisionado

1. Explicação do Problema

O problema abordado neste projeto consiste na **Segmentação Automática de Clientes de Shopping**, utilizando variáveis financeiras cruciais: a Renda Anual e o Score de Gastos (um indicador de fidelidade de 1 a 100). Este ambiente opera sob o paradigma do Aprendizado Não Supervisionado, o que significa que o sistema recebe exclusivamente os dados de entrada (X) sem qualquer rotulação, classe ou gabarito prévio (Y). O sistema deve, portanto, descobrir por conta própria a estrutura geométrica latente dos dados.




Figura 1 – Gráfico contendo cenário inicial de 600 clientes não rotulados.

2. Descrição Detalhada dos Algoritmos

2.1. K-Means Clustering

Para implementar o pipeline do **K-Means**, o script executa um fluxo sequencial rígido:

- **Padronização Z-Score:** Como o K-Means baseia-se estritamente no cálculo da distância euclidiana, os dados originais foram transformados via

StandardScaler(). Isso garantiu que a escala da Renda (até 120) não dominasse geometricamente o Score de Gastos (até 100) .

- **Varredura de Inércia (Método do Cotovelo):** O algoritmo foi executado de forma iterativa dentro de um laço testando de $K=1$ a $K=10$. A cada iteração, capturou-se a métrica *inertia_* (WCSS).
- **Seleção Automatizada via Silhouette Score:** Para eliminar a necessidade de uma escolha humana arbitrária, o script calcula o **coeficiente de Silhueta** para cada K a partir de $K=2$.




Figura 2 – Gráfico obtido do Método do Cotovelo

Treinamento e Mapeamento Espacial: Com o $K=4$ fixado, o modelo final foi treinado (*fit_predict*). Para tornar o gráfico do topo interpretável, o script executa uma malha densa de testes invisíveis (*np.meshgrid*) associada ao método *.predict()*, renderizando no fundo do gráfico o sombreamento contínuo das **Fronteiras de Voronoi**.




Figura 3 – Centróides Fundamentais e Fronteiras de Voronoi

2.2. DBSCAN

Para a modelagem do **DBSCAN**, a estratégia de utilização mudou completamente, abandonando o conceito de centros fixos para escanear a topologia do espaço:

- **Calibragem do Raio Epsilon (ϵ):** Definimos o hiperparâmetro $eps=0.21$ atuando diretamente na escala padronizada, estabelecendo a régua métrica para o tamanho da vizinhança local de cada cliente.
- **Definição de Densidade Mínima (MinPts):** Fixamos $min_samples=5$, forçando o algoritmo a exigir que um ponto possua no mínimo 5 vizinhos dentro do seu **raio ϵ** para ser validado como uma região de alta densidade (Core Point).
- **Mapeamento e Isolamento de Ruídos:** Ao rodar o `.fit_predict()`, o algoritmo agrupou recursivamente os pontos densamente conectados. Aqueles registros gerados aleatoriamente pelo script que caíram nos espaços vazios do gráfico receberam automaticamente o **rótulo -1**. O script utiliza uma máscara booleana (`labels_dbscan == -1`) para isolar esses índices e plotá-los como anomalias.

3. Resultados Obtidos e Análise de Perfis




Figura 4 – Gráficos obtidos a partir de cada algoritmo

Tabela 1: Tradução e Interpretação dos Perfis de Consumo Encontrados

Label do Gráfico	Posição no Espaço	Significado Comercial
Clientes VIP	Renda Alta e Gasto Alto	Consumidores de alto poder aquisitivo e alta fidelidade.
Clientes Impulsivos	Renda Baixa e Gasto Alto	Clientes com forte tração de consumo, mas menor lastro financeiro.
Clientes Conservadores	Alta e Gasto Baixo	Público com alto poder de compra, mas muito reticente nos gastos.
Clientes Ocasionais	Renda Baixa e Gasto Baixo	Consumidores de baixa frequência e pouca tração financeira.
Outliers Isolados	Pontos vermelhos perdidos no vazio	Anomalias estatísticas puras (ruídos de mercado).

A partir do processamento estatístico das médias de Renda e Gastos de cada cluster, foi realizada a decodificação analítica dos rótulos numéricos para categorias reais de mercado:

4. Considerações Finais

A análise comparativa evidencia o impacto da escolha do algoritmo no tratamento de dados ruidosos. O **K-Means**, embora preciso no cálculo dos centros de massa guiados pelo **Silhouette Score** ($K=4$), demonstrou fragilidade perante anomalias. Por sua natureza matemática particional, ele é obrigado a categorizar 100% das entradas, expandindo suas **fronteiras de Voronoi** até as bordas do gráfico. Esse comportamento forçou a inclusão dos pontos isolados nos clusters legítimos, deslocando os centróides e inserindo impurezas estatísticas no perfilamento das classes.

Em contrapartida, a utilização do **DBSCAN** foi mais eficiente. Operando por densidade local ($\epsilon=0.21$ e $MinPts = 5$), o algoritmo contornou a forma orgânica dos dados, mapeando com perfeição as 4 massas principais de consumo que a rigidez esférica do K-Means tendeu a distorcer. Sua maior contribuição prática foi a blindagem absoluta contra ruídos (**outliers**): todos os pontos atípicos dispersos aleatoriamente no espaço foram detectados e destacados com o marcador "X" vermelho, permitindo isolar anomalias financeiras e comportamentais sem consentir que elas corrompessem o perfilamento e a pureza dos grupos de clientes legítimos da organização.