

Inteligência Artificial | FGA0021 | Turma 01 | 2026.1

Professor: Dr. Fabiano Araujo Soares

Aluno: Bruno Cruz Garcia Rosa

Matrícula: 222006605

Aprendizado Supervisionado

1. Explicação do Problema

O problema abordado neste projeto consiste na **Deteção de Fraudes em Transações de Cartão de Crédito**, caracterizando-se como uma tarefa clássica de Classificação Binária dentro do Aprendizado Supervisionado, onde o modelo deve discriminar se uma transação é Legítima (Classe 0) ou Fraude (Classe 1).

O maior desafio técnico deste cenário reside no **desbalanceamento crítico dos dados**. No ambiente real, transações fraudulentas representam uma fração minúscula do volume total (neste experimento, fixada em 1%). Caso um modelo computacional tente apenas minimizar o erro global sem um tratamento prévio, ele cairá na "Armadilha da Acurácia": um classificador ingênuo que rotule 100% das entradas como legítimas obterá uma acurácia aparente de 99%. Contudo, esse sistema será um fracasso prático completo, pois deixará passar todas as fraudes, gerando prejuízos financeiros severos. Portanto, o objetivo central é construir um modelo que neutralize esse viés estatístico.

2. Descrição Detalhada dos Algoritmos

2.1. Random Forest Classifier (Floresta Aleatória)

O algoritmo principal adotado foi o **Random Forest**, um método de aprendizado baseado em conjunto (*Ensemble Learning*). Em vez de confiar em uma única Árvore de Decisão — que possui alta tendência ao *overfitting* —, o Random Forest constrói uma "floresta" com múltiplas árvores de decisão independentes operando em paralelo.

- Amostragem Bootstrap: Cada árvore individual é treinada com uma subamostra aleatória diferente, extraída do conjunto original.

- Seleção Aleatória de Características: Ao criar as divisões (nós) de cada árvore, o algoritmo seleciona um subconjunto aleatório de variáveis, garantindo que as árvores fiquem descorrelacionadas entre si.
- Votação da Maioria: A predição final do modelo é obtida através do voto de maioria de todas as árvores construídas.

2.2. SMOTE (Synthetic Minority Over-sampling Technique)

Como contribuição relevante para mitigar o desbalanceamento dos dados, aplicou-se a técnica **SMOTE** no conjunto de treinamento. Em vez de simplesmente duplicar os registros da classe minoritária (o que causaria sobreajuste), o SMOTE atua de forma geométrica:

- Identifica os vizinhos mais próximos da classe minoritária (Fraudes).
- Desenha um vetor (linha reta) unindo esses pontos no espaço multidimensional de características.
- Cria novas amostras sintéticas matemáticas em posições aleatórias ao longo dessa linha, equalizando perfeitamente a proporção entre as classes antes da etapa de treino.

2.3. Otimização de Hiperparâmetros via GridSearchCV

Para maximizar a performance e evitar escolhas arbitrárias de configuração, utilizou-se o **GridSearchCV**. Essa ferramenta realiza uma varredura exaustiva cruzando um dicionário de parâmetros predefinidos (testando *max_depth*: [3, 5, 10] e *n_estimators*: [10, 50, 100]). O processo utiliza **Validação Cruzada (Cross-Validation)** dividindo o treino em 3 blocos (*folds*), garantindo que a escolha final seja estatisticamente robusta e focada em otimizar a métrica F1-Score.

3. Resultados Obtidos

Figura 1 - Matrizes de Confusão geradas para cada cenário explorado




Tabela 1: Distribuição dos Dados de Treinamento

Estado do Conjunto de Treino	Transações Legítimas (Classe 0)	Transações de Fraude (Classe 1)
Original (Desbalanceado)	7425	75
Após aplicar SMOTE	7425	7425

Tabela 2: Matrizes de Confusão Obtidas no Teste

Cenário Avaliado	Verdadeiros Negativos (Legítimas Corretas)	Falsos Positivos (Alarmes Falsos)	Falsos Negativos (Fraudes Perdidas)	Verdadeiros Positivos (Fraudes Detectadas)
Desbalanceado	2475	0	21	4
Smote	2261	214	5	20
Smote + GridSearch	2376	99	9	16

Tabela 3: Relatório Comparativo de Métricas

Cenário Avaliado	Acurácia Geral	Precisão (Fraude)	Recall / Sensibilidade (Fraude)	F1-Score (Fraude)

Desbalanceado	99.16%	1.00	0.16	0.28
Smote	91.24%	0.09	0.80	0.15
Smote + GridSearch	96.00%	0.14	0.64	0.23

4. Considerações Finais

A análise comparativa dos três cenários revela o claro impacto da engenharia de dados e do ajuste de hiperparâmetros na resolução de problemas complexos.

O **Cenário 1** evidencia o perigo de se avaliar um modelo desbalanceado apenas por sua acurácia (99.16%). Ele obteve essa nota alta ignorando completamente a existência de 84% das fraudes reais, provando-se inútil para a segurança bancária.

O **Cenário 2 (Apenas SMOTE)** solucionou o problema de detecção aumentando o *Recall* das fraudes para 80% (capturando 20 das 25 infrações). No entanto, operando com uma profundidade rasa (*max_depth=5*), ele cobrou um preço operacional altíssimo: gerou 214 alarmes falsos, o que em um cenário real sobrecarregaria o suporte do banco e causaria atrito com clientes legítimos, resultando em um baixo F1-Score (0.15).

O **Cenário 3 (SMOTE + GridSearchCV)** provou ser a solução ideal ao encontrar de forma automatizada a configuração mais profunda (*max_depth=10*). O algoritmo realizou um *trade-off* (compensação) inteligente: cedeu ligeiramente o recall de fraude para 64% (capturando 16), mas reduziu drasticamente os alarmes falsos de 214 para apenas 99. Como consequência, elevou a acurácia geral para 96% e alcançou o **maior F1-Score (0.31)** do experimento.

Em suma, conclui-se que o uso do **SMOTE** é indispensável para dar representatividade a classes minoritárias, mas ele precisa ser obrigatoriamente acompanhado por uma otimização como o **GridSearchCV** para refinar as fronteiras de decisão e garantir a viabilidade prática do Modelo.