

Inteligência Artificial | FGA0021 | Turma 01 | 2026.1

Professor: Dr. Fabiano Araujo Soares

Aluno: Bruno Cruz Garcia Rosa

Matrícula: 222006605

Filtro de Kalman

1. Explicação do Problema

Este projeto aborda o problema de filtragem cinemática bidimensional e estimação de variáveis ocultas através de um **Filtro de Kalman Linear** de base 6D. O objetivo é estimar a trajetória contínua de um veículo que executa curvas agressivas em formato de "S", limpando o **ruído** de alta frequência de um GPS posicional de baixa precisão ao fundi-lo com o modelo físico-matemático da mecânica clássica aplicável a dois eixos, simultaneamente.

2. Descrição Detalhada do Algoritmo Desenvolvido

O modelo matemático foi desenvolvido utilizando operações matriciais do **NumPy**. O vetor de estado foi parametrizado com dimensão 6x1 para acomodar a posição (x,y), a velocidade (v) e a aceleração (a) em ambos os eixos cartesianos (x, v_x , a_x , y, v_y , a_y).

2.1. Pré-requisitos de Instalação

Para executar o script e gerar os painéis estatísticos, é necessário instalar o pacote de plotagem via terminal:

```
pip install numpy matplotlib
```

2.2. Arquitetura

O algoritmo do **Filtro de Kalman** executa uma **inicialização**, seguida por um laço iterativo eterno composto pelas etapas de **Predição** (atualização no tempo) e **Atualização** (correção pela medição):

- **Modelo Cinemático de Base**

A dinâmica de movimentação contínua do veículo no plano bidimensional é regida pelas equações diferenciais da cinemática mecânica clássica. Para projetar o estado atual do sistema para um instante futuro $t + \Delta t$, o **Filtro de Kalman** baseia-se nas fórmulas do **Movimento Retilíneo Uniformemente Variado (MRUV)**:

$$s_{t+\Delta t} = s_t + v_t \cdot \Delta t + \frac{1}{2}a_t \cdot \Delta t^2$$

$$v_{t+\Delta t} = v_t + a_t \cdot \Delta t$$

$$a_{t+\Delta t} = a_t$$

Figura 1 - Fórmulas MRUV utilizadas.

Como os movimentos nos eixos X e Y são ortogonais e independentes, essas três equações são aplicadas simultaneamente para ambas as dimensões. Nessa modelagem, a aceleração é tratada de forma simplificada como **constante** entre cada frame ($a(t+\Delta) = a(t)$), deixando que as oscilações dinâmicas reais (**senoidais e cossenoidais**) sejam absorvidas e corrigidas pela matriz de ruído de processo Q . Ao isolarmos os coeficientes lineares de cada variável de estado, estruturamos a matriz de transição dinâmica $A_{6 \times 6}$ de forma blocada, onde os elementos nulos garantem o isolamento físico entre os eixos:

$$A = \begin{bmatrix} 1.0 & dt & 0.5 \cdot dt^2 & 0.0 & 0.0 & 0.0 \\ 0.0 & 1.0 & dt & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 1.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 1.0 & dt & 0.5 \cdot dt^2 \\ 0.0 & 0.0 & 0.0 & 0.0 & 1.0 & dt \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 & 1.0 \end{bmatrix}$$

Figura 2 - Matriz de transição. $dt = \Delta t$.

- **Inicialização do Sistema**

No instante inicial ($t=0$), a estimativa de estado é ancorada na primeira amostragem disponível do sensor de posição, enquanto as taxas derivadas (velocidade e aceleração) são assumidas como zero, conforme expresso no vetor x_0 . A matriz de covariância inicial do erro (P_0) é definida como $P_0 = I_{6 \times 6} \cdot 10$. A **matriz de observação linear** $H_{2 \times 6}$ isola as componentes mensuráveis de posição do vetor de estado.

$$\hat{x}_0 = \begin{bmatrix} x_{m_1} \\ 0 \\ 0 \\ y_{m_1} \\ 0 \\ 0 \end{bmatrix} \quad \text{e} \quad H = \begin{bmatrix} 1.0 & 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 1.0 & 0.0 & 0.0 \end{bmatrix}$$

Figura 3 - Matriz de estados inicial e Matriz de observação, respectivamente.

- **Predição (Time Update)**

A cada incremento temporal de $\Delta t = 0.1s$, o filtro projeta o vetor de estado e a sua matriz de incerteza para o instante seguinte com base nas seguintes equações:

$$\hat{x}_{k|k-1} = A \cdot \hat{x}_{k-1|k-1}$$

$$P_{k|k-1} = A \cdot P_{k-1|k-1} \cdot A^T + Q$$

Figura 4 - Fórmulas utilizadas para cálculos de predição.

Onde Q é a **matriz de covariância** do ruído de processo (6x6). Ela introduz pequenas incertezas incrementais no modelo para simular perturbações externas do mundo real (como vento ou imperfeições da pista).

- **Atualização (Measurement Update)**

Assim que o sensor de GPS emite uma nova leitura posicional ($Z_{2 \times 1}$), o algoritmo calcula o **Ganho de Kalman** (K). Esse operador funciona como um balanceador de confiança estatística baseado na covariância de medição $R_{2 \times 2}$.

$$K_k = P_{k|k-1} \cdot H^T \cdot (H \cdot P_{k|k-1} \cdot H^T + R)^{-1}$$

Figura 5 - Fórmula utilizada para o Ganho de Kalman.

Com o ganho calculado, a estimativa prevista é corrigida gerando o estado ótimo atualizado através do vetor de inovação, e a matriz de incerteza P é correspondentemente atenuada:

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \cdot (Z_k - H \cdot \hat{x}_{k|k-1})$$

$$P_{k|k} = (I - K_k \cdot H) \cdot P_{k|k-1}$$

Figura 6 - Fórmulas utilizadas para correção da estimativa prevista e atualização da matriz de incerteza, respectivamente.

3. Resultados Obtidos e Análise das Variáveis Ocultas

A simulação do veículo de alta performance foi submetida a restrições estocásticas, configurando uma **variância de erro do GPS** de $R = 8.0$ (desvios médios de ± 2.82 metros nas coordenadas) e uma incerteza de processo de $Q = 0.2$. O veículo executou curvas em formato de "S" comandadas por forças de aceleração variáveis senoidais ao longo de 20 segundos de amostragem ($t=200$ passos). O comportamento prático do estimador construído pode ser validado diretamente através da análise das Figuras 6 e 7:

- **Análise de Posição (Figura 7):** O gráfico do Eixo Y evidencia o forte ruído do GPS (pontos vermelhos), que dispersa a trajetória a olho nu. O Filtro de Kalman (linha verde tracejada) eliminou essa alta frequência, reconstruindo uma curva suave e aderente ao traçado real (linha azul).

- **Estimação Oculta (Figura 8):** Demonstra a dedução da aceleração no Eixo X a partir de mudanças posicionais no tempo, contornando a ausência de leituras diretas pela matriz H . O pico inicial (linha verde) indica o período de convergência do filtro, que partiu do repouso com o veículo já em movimento. Após esse ajuste, o algoritmo rastreou com maior precisão a amplitude e a frequência da cossenoide real (linha azul).




Figura 7 - Gráfico gerado a partir da análise da posição no eixo Y.




Figura 8 - Gráfico gerado a partir da análise da aceleração no eixo X.